MOHAMED NABIL OUAJA

Recherche Stage PFE – Data Science (6 mois), dès février 2027

+212 774 208 958 | mnouaja@insea.ac.ma | Rabat, Maroc | Permis B
linkedin | portfolio

PROFIL

Élève ingénieur en 3e année Data Science à l'INSEA, axé sur la modélisation statistique, le Machine Learning, les LLMs et le Data Engineering : conception de pipelines de données complexes (ETL/MLOps), intégration d'agents intelligents (RAG) et déploiement d'applications data prédictives (API REST, dashboards). Je recherche un stage PFE de 6 mois pour concevoir, optimiser et mettre en production des solutions Data & IA à forte valeur ajoutée.

FORMATION

Cycle d'Ingénieurs en Data Science, INSEA, Rabat **2024 – Présent**
Statistique et Économie Appliquée – Machine Learning, Deep Learning, NLP, Statistiques avancées, Séries chronologiques.

Classes Préparatoires aux Grandes Écoles (CPGE), ALQALAM, Agadir **2022 – 2024**
Filière PSI (Physique et Sciences de l'Ingénieur).

Baccalauréat — Sciences Physiques , Lycée Hassan II, Tiznit **2022**

EXPÉRIENCE

Data Scientist Intern **Juil. – Août 2026**
Alveris Group, Paris, France

— Conception et déploiement de bout en bout d'un pipeline automatisé de trading quantitatif et de gestion des risques, nommé Alveris Quant Desk.

Data Analyst Intern **Juil. 2025**
Haut Commissariat au Plan, Agadir, Maroc

— Analyse statistique et traitement des données de l'Enquête Nationale sur la Famille.

PROJETS

Application RAG & Agent LLM local github
Développement d'un assistant documentaire intelligent exploitant une architecture RAG et des agents LangChain (ReAct) couplés à des LLMs locaux (Ollama) et une base vectorielle (ChromaDB) via une interface Streamlit.

Détection de Fraudes Bancaires github
Conception d'un pipeline Machine Learning de détection de fraudes sur données très déséquilibrées (AUPRC 0,8690) combinant RobustScaler, SMOTE et des modèles d'ensemble (Random Forest, XGBoost, LightGBM).

NLP Spam Detection github
Développement d'un classifieur de spams intégrant un algorithme Naive Bayes multinomial implémenté *from scratch* et comparé aux modèles LDA, QDA, Régression Logistique et SVM.

Tableau de Bord de Suivi de la Sécheresse github
Création d'un tableau de bord décisionnel de suivi de la sécheresse alimenté par un pipeline d'extraction satellitaire (GEE, Python, NDVI) et restitué sous Power BI.

Séries Chronologiques – Faillites d'Entreprises github
Modélisation et prévision trimestrielle des faillites d'entreprises parisiennes (1995–2021) par analyse de séries temporelles SARIMA sous R (`tseries`, `forecast`).

ENGAGEMENT & DISTINCTIONS

Chef de cellule logistique & événements – *INSEA-IT, Rabat* **Nov. 2024 – Présent**
Organisation des événements du club (IT-Village...) ; leadership, rigueur, travail sous pression.

CERTIFICATIONS

— **IBM :** Python for Data Science | **NVIDIA :** Fundamentals of Deep Learning | **Simplilearn :** Java Programming

COMPÉTENCES & LANGUES

— **IA générative & NLP :** RAG, Agents LLM (ReAct), LangChain, ChromaDB, Ollama, Transformers
— **Machine Learning :** Scikit-Learn, XGBoost, LightGBM, SMOTE, Pandas, NumPy, Matplotlib
— **Programmation :** Python, R, SQL, C, Java, Git, Jupyter Notebook
— **Data Engineering :** ETL, Airflow, FastAPI, Docker, Kubernetes, dbt, DuckDB, MySQL, Oracle, PostgreSQL
— **Visualisation :** Power BI, Streamlit, Google Earth Engine
— **Langues :** Arabe (langue maternelle), Français (B2), Anglais (B1)